

تمرینات کلاسی هفته ششم - سری اول

=====

10 سوال سرعتی

سؤال ۱ - قاعده‌ی بیز

فرض کنید $P(\text{girl}) = 0.6$ و $P(\text{boy}) = 0.4$. در نقطه‌ی x ، چگالی‌ها این‌طور اندازه‌گیری شده‌اند:

$$p(x|\text{girl}) = 0.5 \text{ و } p(x|\text{boy}) = 0.2$$

مدل بیز در این نقطه چه کلاسی را پیش‌بینی می‌کند؟

سؤال ۲ - رگرسیون خطی

یک مدل معادله‌ی $\hat{y} = 10 + 2x$ را یاد گرفته. برای $x=4$ ، مدل چه چیزی پیش‌بینی می‌کند؟ اگر مقدار واقعی y برابر ۲۱ باشد، باقی‌مانده (residual) چقدر است؟

سؤال ۳ - یک KNN خیلی ساده

با numpy دو گروه داده بسازید: گروه اول حول عدد ۲ و گروه دوم حول عدد ۸ (هرکدام ۵۰ نمونه، انحراف معیار ۱). یک KNeighborsClassifier با $k=3$ آموزش دهید و دقتش را روی همان داده چاپ کنید.

سؤال ۴ – مقایسه‌ی چگالی با scipy

با `scipy.stats.norm`، چگالی $x=5$ را برای دو توزیع

$N(4,1)$ و $N(7,1)$

حساب کنید و چاپ کنید کدام یک بزرگ‌تر است. نکته: چون $x=5$ به میانگین گروه دختر (۴) نزدیک‌تر است تا میانگین گروه پسر (۷)، انتظار داریم چگالی دختر بزرگ‌تر باشد.

سؤال ۵ – برازش رگرسیون خطی

داده‌ی مصنوعی حول رابطه‌ی $y = 3x + 5$ (با کمی نویز) بسازید و یک `LinearRegression` رویش برازش دهید. شیب و عرض از مبدأ یادگرفته‌شده را چاپ کنید.

سؤال ۶ – یک رگرسیون لجستیک ساده

یک داده‌ی دوکلاسه (شبیه سؤال ۳) بسازید و یک `LogisticRegression` رویش آموزش دهید. دقت مدل را چاپ کنید.

سؤال ۷ – پیاده‌سازی تابع سیگموید

تابعی به نام `sigmoid` بنویسید که مقدار

$$1 / (1 + e^{-z})$$

را برمی‌گرداند و آن را برای $z = -5, 0, 5$ تست کنید.

سؤال ۸ – امتحان چند مقدار k در KNN

با داده‌ی سؤال ۳، سه مدل KNN با $k=5$ ، $k=1$ ، و $k=20$ بسازید و دقت هرکدام را چاپ کنید.

سؤال ۹ – مرور آمار توصیفی با `pandas/numpy`

یک آرایه از ۱۰ عدد دلخواه به‌عنوان «سطح هورمون» بسازید و میانگین و انحراف‌معیارش را چاپ کنید.

سؤال ۱۰ – ماتریس درهم‌ریختگی (Confusion Matrix)

روی مدل رگرسیون لجستیک سؤال ۶، ماتریس درهم‌ریختگی را چاپ کنید و بگویید مدل چند مورد را درست و چند مورد را اشتباه پیش‌بینی کرده.

=====

راند ۱ – فکر کردن به سبک بیز

۱.۱ – بحث کنید (نیازی به محاسبه نیست). یک هواشناس می‌گوید: «طبق آمار سال‌های قبل، در فصل باران ۸۰٪ روزها تا عصر باران می‌بارد.» این باور اولیه اوست، قبل از این که به بیرون نگاه کند. بعد سرش را بلند می‌کند و ابرهای سیاه و سنگین می‌بیند. حالا تخمینش از «احتمال بارش امروز» به ۹۵٪ می‌رسد.

به آن باور اولیه ۸۰٪ اصطلاحاً چه می‌گویند؟

به این باور به روزشده ۹۵٪ (بعد از دیدن شواهد) اصطلاحاً چه می‌گویند؟

در یک جمله، با کلمات خودتان توضیح دهید چه چیزی عدد اول را به عدد دوم تبدیل می‌کند.

۱.۲ – درست یا غلط (دلیل بیاورید). «احتمال این که یک دختر بچه به طور تصادفی انتخاب شده، سطح تاو-هورمونش دقیقاً ۴.۰۰۰۰۰ باشد، ۷۰٪ است.»

۱.۳ – فرض کنید در سطح هورمونی $x=5$ ، چگالی‌های شرطی زیر را (ساده شده، فقط برای این تمرین) اندازه‌گیری کرده ایم:

$p(x=5 \mid \text{کلاس})$

دختر: ۰.۲۸

پسر: ۰.۱۵

احتمال‌های پیشین را هم به یاد بیاورید:

$P(0.3 = \text{پسر})$ ، $P(0.7 = \text{دختر})$.

مقادیر وزن دار

$p(x \mid \text{پسر}) * P(\text{پسر} \mid \text{دختر})$ و $p(x \mid \text{دختر}) * P(\text{دختر})$

را حساب کنید. قاعده بهینه بیز در $x=5$ کدام کلاس را پیش‌بینی می‌کند؟ چرا؟

=====

راند ۲ – آشنایی با KNN

۲.۱ – در دو یا سه جمله، به هم گروهی هایتان (به زبان ساده، بدون فرمول) توضیح دهید KNN چطور کلاس یک نقطه جدید را تعیین می کند.

۲.۲ – دستی حساب کنید. این هم یک مجموعه آموزشی کوچک از نوزادان و سطح تاو-هورمون شان:

سطح هورمون	برچسب
۳.۸	دختر
۴.۲	دختر
۵.۰	دختر
۵.۹	پسر
۶.۵	پسر
۷.۰	پسر
۷.۸	پسر

یک نوزاد جدید $x=6.2$ اندازه گیری شده. با $k=3$:

سه نقطه آموزشی نزدیک تر را لیست کنید. رای اکثریت چیست؟ KNN چه چیزی پیش بینی می کند؟

۲.۳ – ارتباط را پیدا کنید. در نوت بوک گفته شده بود: «اگر k دختر تا از k همسایه نزدیک شما دختر باشند، آنگاه k دختر / k تقریباً برابر است با $P(\text{دختر} | x)$ ».

با کلمات خودتان توضیح دهید چرا تراکم بیشتر نقاط دختر نزدیک x به طور طبیعی باعث می شود دختر بیشتری بین نزدیک ترین همسایه ها ظاهر شود. (راهنمایی: به این فکر کنید که «چگالی بالا» و «پیشین بالا» واقعا چه تاثیری روی تعداد نقاطی که در آن نزدیکی قرار می گیرند دارند.)

۲.۴ – موازنه‌ی بایاس-واریانس. برای هر کدام از سه حالت زیر، توضیح دهید مدل چطور رفتار می‌کند و آیا در حالت بیش‌برازش است یا کم‌برازش:

- $k=1$
- متوسط k یک
- $k=n$ (یعنی برابر با تعداد کل نقاط آموزشی)

=====

راند ۳ – یک نوت بوک/اسکرپت تازه باز کنید. این ایمپورت ها را اجرا کنید:

```
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats
np.random.seed(42)
```

۳.۱ – دو توزیع زیر را تعریف کنید:

```
girl_dist = stats.norm(4.0, 1.2)
boy_dist = stats.norm(7.0, 1.5)
```

هر دو تابع چگالی احتمال را روی

```
x = np.linspace(0, 12, 1000)
```

رسم کنید، درست مثل کلاس.

۳.۲ – حالا فرض کن میانگین پسرها به جای ۷، برابر ۶ باشه (یک توزیع جدید بساز، توزیع قبلی رو دستکاری نکن). دوباره هر دو منحنی رو رسم کن. بین این دو حالت (میانگین ۷ در مقابل میانگین ۶)، در کدام حالت دو منحنی هم‌پوشانی بیشتری دارن؟ با توجه به این هم‌پوشانی، انتظار داری خطای بهینه‌ی بیز (Bayes error) در کدام حالت بیشتر باشه؟ توضیح بده چرا.

۳.۳ – مرز تصمیم را به صورت عددی پیدا کنید. با استفاده از توزیع های اصلی (میانگین پسر = ۷)، کدی بنویسید که:

```
g = girl_dist.pdf(x) * P_GIRL و b = boy_dist.pdf(x) * P_BOY
```

رو حساب کنه (با $P_GIRL=0.7$, $P_BOY=0.3$)
نقطه‌ای که g برای اولین بار از b کمتر می‌شه رو پیدا کنه و مقدارش رو چاپ کنه.

۳.۴ – $n = 5000$ نوزاد بساز (۷۰٪ دختر و ۳۰٪ پسر، آرایه‌ی X (ستونی) و y ، عدد ۰ یعنی دختر، ۱ یعنی پسر). داده را به آموزش/آزمون تقسیم کنید (۷۰/۳۰)، و یادتان باشد $stratify=y$ را بگذارید. یک $KNeighborsClassifier$ با $n_neighbors=15$ آموزش دهید.
دقت روی داده آزمون را چاپ کنید.
آیا انتظار دارید این دقت کامل (۱.۰) باشد؟ چرا؟

۳.۵ – کد زیر خطا می دهد. دو باگ را پیدا کرده و درستش کنید.

```
from sklearn.neighbors import KNeighborsClassifier
from sklearn.model_selection import train_test_split
X = girl_dist.rvs(3500) # سطرهای هورمونی
y = [0]*3500
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3)
knn = KNeighborsClassifier(n_neighbors=15)
knn.fit(X_train, y_train)
```

(راهنمایی: دو ایراد جدا از هم اینجا هست – یکی درباره شکلی که scikit-learn انتظار دارد، و یکی درباره این که آیا اصلاً این مجموعه داده چیز مفیدی برای یاد دادن به یک طبقه بند دارد یا نه.)

=====

راند ۴ – مبانی رگرسیون خطی

۴.۱ – پنج دانشجو ساعت مطالعه هفتگی و نمره امتحانشان را در جدول زیر گزارش کرده اند:

ساعت مطالعه (x)	نمره (y)
2	65
4	70
6	75
8	85
10	90

با استفاده از فرمول های کلاس:

$$w1 = \frac{\sum((x_i - \text{mean}(x)) * (y_i - \text{mean}(y)))}{\sum((x_i - \text{mean}(x))^2)}$$

$$w0 = \text{mean}(y) - w1 * \text{mean}(x)$$

حالا

mean(x) و mean(y)

را حساب کنید. w0 و w1 را حساب کنید.

معادله برازش شده نهایی $\hat{y} = w0 + w1 * x$ را بنویسید.

۴.۲ – توضیح دهید w0 و w1 در بافت این مسئله (ساعت مطالعه و نمره امتحان) به چه معنايند.

۴.۳ – با استفاده از معادله خودتان در ۴.۱، نمره دانشجویی را که ۶ ساعت مطالعه کرده پيش بينی کنید. اين پيش بينی را با نمره واقعی گزارش شده برای ۶ ساعت در جدول بالا مقایسه کنید. باقی مانده (residual) چقدر است؟ آیا مدل برای این دانشجو بیش از حد یا کمتر از حد پيش بينی می کند؟

۴.۴ – برای یک مجموعه داده دیگر، $SS_{\text{res}} = 50$ و $SS_{\text{tot}} = 500$ است. R^2 را حساب کنید. به زبان ساده، این مقدار چه چیزی درباره‌ی کیفیت مدل می گوید؟

۴.۵ – چرا در تابع هزینه (MSE) به جای این که باقی مانده های خام را مستقیم با هم جمع کنیم، آنها را به توان دو می رسانیم؟ (راهنمایی: فکر کنید چه اتفاقی می افتد اگر بعضی باقی مانده ها مثبت و بعضی منفی باشند).

=====

راند ۵ – برازش یک خط

۵.۱ – دکتر لیند، دانه های قهوه را برشته می کند و می خواهد درصد کاهش وزن حین برشته شدن را از روی زمان برشته شدن (دقیقه) پیش بینی کند. داده مصنوعی زیر را بسازید:

```
import numpy as np
np.random.seed(0)
n = 100
roast_time = np.random.uniform(8, 18, n)
weight_loss = 2.0 + 0.9 * roast_time + np.random.normal(0, 1.5, n)
```

نمودار پراکندگی roast_time در مقابل weight_loss را رسم کنید.
یک مدل LinearRegression برازش دهید (یادتان باشد: roast_time باید به شکل ستونی درآید).
عرض از مبدا و شیب یادگرفته شده، مقدار MSE، و مقدار R^2 را چاپ کنید.

۵.۲ – داده ی خام رو به صورت پراکندگی رسم کنید، خط برازش شده را رویش بکشید.

۵.۳ – ۵.۱ را دوباره انجام دهید، اما این بار نویز را به

```
np.random.normal(0, 4.0, n)
```

تغییر دهید (داده پرنویزتر).

R^2 نسبت به ۵.۱ چگونه تغییر می کند؟

۵.۴ – از جدول ۴.۱ آرایه های X و y بسازید، یک LinearRegression رویشان برازش دهید، آیا شیب و عرض از مبدا یی که sklearn پیدا می کنه، با چیزی که در ۴.۱ دستی حساب کردید یکیه؟

=====

راند ۶ – رگرسیون لجستیک و تابع سیگموید

۶.۱ – یک خط $w_0 + w_1 * x$ می تواند هر عدد حقیقی ای، از منفی بینهایت تا مثبت بینهایت بدهد. اگر بخواهیم یک احتمال پیش بینی کنیم، این چرا مشکل ساز است؟ رگرسیون لجستیک برای حل این مشکل چه کار می کند؟

۶.۲ – سیگموید

$$\text{sigma}(z) = 1 / (1 + e^{-z})$$

را به یاد بیاورید:

$$\text{sigma}(0)$$

دقیقا چقدر است؟

$$\text{sigma}(-2)$$

به ۰ نزدیک تر است یا به ۱؟ با آستانه معمول ۰.۵، این چه کلاسی را پیش بینی می کند؟

$$\text{sigma}(3)$$

به ۰ نزدیک تر است یا به ۱؟ این چه کلاسی را پیش بینی می کند؟

۶.۳ – یک مدل رگرسیون لجستیک روی داده تاو-هورمون برآزش داده شده و $w_1 = 1.2$ ، $w_0 = -7.26$ به دست آمده.

مقدار x ای را حل کنید که در آن

$$w_0 + w_1 * x = 0$$

(این همان مرز تصمیم است، جایی که مدل دقیقا ۵۰/۵۰ پیش بینی می کند).

این مقدار را با مرز بهینه بیز که در راند ۳.۲ به صورت عددی حساب کردید مقایسه کنید. چه چیزی متوجه می شوید؟

=====

راند ۷ – سبد ترکیبی

۷.۱ – برای هر سناریوی زیر، تصمیم بگیرید کدام ابزار بهترین گزینه است: رگرسیون خطی، رگرسیون لجستیک، KNN

الف) پیش بینی قیمت فروش یک خانه از روی متراژ و تعداد اتاق خواب.

ب) پیش بینی این که آیا یک تراکنش ورودی تقلبی است یا نه، در حالی که یک تخمین احتمالی هم می خواهیم.

ج) طبقه بندی یک میوه جدید به عنوان رسیده یا نارس، با مقایسه رنگ و سفتی اش با میوه های مشابه از قبل برچسب خورده.

د) تخمین فروش بستنی ماه آینده از روی میانگین دمای روزانه.

۷.۲ – یک مدل با واریانس بالا با داده‌ی آموزشی چیکار می‌کند، و روی داده‌ی جدید چطور عمل می‌کند؟

یک مدل با بایاس بالا چه مشکلی دارد، و روی داده‌ی آموزشی و جدید چطور عمل می‌کند؟

۷.۳ – درست یا غلط

الف) «KNN در زمان آموزش، یک معادله ریاضی ثابت یاد می‌گیرد، شبیه رگرسیون خطی.»

ب) « R^2 برابر با صفر همیشه یعنی مدل کاملاً بی فایده است و هیچ اطلاعاتی نمی‌دهد.»